

SKN30 1Team · CassTerra

SalesLuv

영업의 흐름을 연결하는 멀티에이전트 CRM

CONNECT THE HISTORY.

APPROVE THE NEXT MOVE.

2026.09.18 (FRI) 15:00

천성배 · 정주애 · 박제섭 · 박지유

문제 → 구현 → 검증, 세 파트로 설명합니다

01

문제 정의

왜 이 문제를 골랐는가

팀 · 주제 · 문제

시장 · 경쟁 · 해결책 · 기대효과

02

설계와 구현

무엇을 어떻게 만들었는가

시나리오 · 시연 · 기술 스택

아키텍처 · 에이전트 · AI 기능

03

검증과 확장

제대로 동작하는지 어떻게 확인했는가

에이전트별 평가 · 일정 에이전트

실패와 개선 · 향후 계획 · 결론

01

문제 정의

왜 이 프로젝트가 필요한가

네 명이 기획부터 배포까지 나눠 맡았다

[PHOTO]

천성배

P.M

OCR

자료요약 Agent

[PHOTO]

정주애

Full Stack

Infra

[PHOTO]

박제섭

기술리더

미팅분석 Agent

업무보고 Agent

[PHOTO]

박지유

영업계약 Agent

일정관리 Agent

시연영상

담당자의 고객 맥락을 팀이 이어받게 한다

영업의 시작부터 끝까지, 한 번에 해결하는 멀티에이전트 CRM

국내 B2B 영업

고객 · 딜 · 일정 · 보고가

흩어져 있는 조직

멀티에이전트

판단 · 초안 · 제안을

다섯 에이전트로 분담

Human-in-the-loop

AI는 초안까지,

확정은 사람의 승인으로

CRM — 고객과 나눈 이야기를 기억하는 시스템

딜 — 하나의 거래 기회

영업 맥락은 다섯 지점에서 끊긴다

- | | | |
|----|------------|------------------------|
| 01 | 영업정보 분산 | 고객 · 계약 · 매출이 따로 관리된다 |
| 02 | 영업흐름 단절 | 리드 → 계약 → 매출이 이어지지 않는다 |
| 03 | 판단 공백 | 진행 상황과 예측이 보이지 않는다 |
| 04 | 인수인계 맥락 소실 | 관계와 노하우가 담당자와 함께 사라진다 |
| 05 | 범용 CRM 한계 | B2B 영업 현장에는 기능이 부족하다 |

결국 남는 문제는 암묵지다

고객 맥락과 영업 노하우는 담당자 개인의 암묵지로만 쌓인다

조직 자산으로 남지 않아 담당자가 바뀌면 함께 사라진다

이 판단의 근거

프로젝트 기획서

2026-08 작성

문제 정의와 범위

현장 경험

영업사원 출신 PM의

실무 경험에서 출발


정량 근거는 없음

설문 · 인터뷰 데이터 없이

검증할 가설로 다룬다

국내 CRM 시장은 2033년까지 두 배 이상 커진다

■ 국내 CRM 시장 규모 (조원)



10.3%

국내 CRM 연평균 성장률
2026-2033

17.1%

국내 SaaS 연평균 성장률
2025-2029 · 2조 1,295억 → 4조 164억

CRM과 SaaS는 시장 정의가 달라 합산하지 않는다 · 영업 CRM 단독 시장 통계는 공개된 것이 없다

진입 조건은 근거 · 연결 · 승인 세 가지다

01

경쟁 현실

AI 미팅 요약과 후속조치
제안은 이미 존재한다

02

초기 ICP

문서 · 견적 · 계약이
복잡한 B2B 영업팀

03

차별화 조건

근거 검색 + 데이터 연결
+ 담당자 승인

성장하는 시장에서 우리가 고른 자리 — 근거를 대고, 데이터를 잇고, 사람이 승인한다

기본 기능은 세 제품 모두 갖추고 있다

제품	고객 · 거래처 관리	파이프라인 · 딜 관리	영업 실적 · 매출 분석
세일즈맵	●	●	●
핑거세일즈	●	●	●
세일즈인사이트	●	●	△
SalesLuv	●	●	●

● 제공 △ 일부 – 공개 자료에서 확인되지 않음

차이는 AI 유무가 아니라 승인이 순환하는 구조다

제품	AI 기능	사용자 승인 후 업무 반영	승인 결과 → 다음 행동 순환
세일즈맵	△	—	—
핑거세일즈	●	●	—
세일즈인사이트	—	—	—
SalesLuv	●	●	●

● 제공 △ 일부 — 공개 자료에서 확인되지 않음

SalesLuv가 더하는 것은 세 가지다

근거 기반 추천

보고서와 자료를 검색해
출처와 함께 제안한다

Human-in-the-loop

AI 제안은 초안일 뿐,
담당자가 확정한다

다음 행동으로 순환

승인 결과가 다시
다음 추천을 부른다

경쟁 제품에도 AI는 있다. 다른 것은 승인 결과가 다음 행동으로 순환하는 구조다

기록이 초안이 되고, 승인이 다음 일정이 된다

01

미팅 기록 입력
원문 · 음성 STT
이미지 OCR



02

AI 초안 + 딜 승산
딜별 귀속 · 13개 특성
성사 확률



03

사람이 확정
근거 대조 · 확정
팀장 검토



04

다음 미팅 · 브리핑
날짜 추천
캘린더 승인

04의 승인 결과가 다시 01로 — 모든 기록은 딜(sales_deal) 하나로 연결된다

파일럿에서 네 개 지표로 검증한다

[수치 입력 예정]

보고서 작성시간

활성 작업시간 중앙값

[수치 입력 예정]

당일 제출률

당일 제출 ÷ 보고 대상

[수치 입력 예정]

필수정보 조회 완성률

첫 제출 필수항목 충족

[수치 입력 예정]

팀장 검토시간

검토 작업시간 중앙값

정량 수치는 파일럿에서 검증할 가설이며 실측값이 아니다

보고서는 아래 단계의 확정본 위에 쌓인다



각 단계는 아래 단계의 확정 제출본을 원천으로 사용한다

정성 효과

자동 집계 · 검증

흩어진 기록을 모아 숫자를 스스로 맞춘다

승인 기반 반영

확정된 내용만 CRM · 캘린더에 반영한다

암묵지의 자산화

개인의 노하우가 조직의 기록으로 남는다

02

설계와 구현

그래서 어떻게 해결했는가

AI는 미팅을 준비하고 기록을 받아 적는다

사용자 시나리오 01 – 03

01

미팅 준비

영업·계약관리 에이전트가
다음 미팅을 추천하고
사람이 캘린더에 승인한다

02

사전 브리핑

과거 보고서와 자료를
RAG로 찾아 근거와 함께
브리핑을 만든다

03

미팅 후 입력

미팅 원문을 직접 쓰거나
음성 파일 STT · 이미지 OCR로
기록을 올린다

여기까지는 모두 AI가 준비한 초안 — 아직 확정된 것은 없다

확정은 사람이 하고, 그 확정이 다음을 부른다

사용자 시나리오 04 – 06

04

보고서 확정

사람이 확정해야

저장된다

AI 단독 저장은 없다

05

보고서 누적

확정본이 RAG에 적재되고

다음 미팅 추천

트리거가 걸린다

06

기간 보고

일일 · 주간 · 월간으로

묶여 팀장 검토로

올라간다

확정 결과가 다시 01 미팅 준비로 순환한다

한 번의 영업 사이클을 실제 화면으로 따라간다


시연 영상 (16:9)

[시연 동선 한 줄 입력 예정]

■ 시연 체크포인트


- 1 자료실 업로드 → 요약
- 2 캘린더 추천 승인
- 3 AI 브리핑 확인
- 4 미팅 원문 → 초안 생성
- 5 보고서 확정 → 다음 추천

이 프로젝트를 만든 기술 조합



LLM gpt-5.6-luna · STT gpt-4o-transcribe · OCR PaddleOCR (RunPod GPU) · provider adapter로 교체 가능

입구는 하나, 오래 걸리는 AI 작업은 따로 뗐다



배포 GitHub Actions → OIDC → SSM 원격 실행 · 무중단 blue / green

다섯 에이전트가 판단 · 초안 · 제안을 나눠 맡는다

미팅분석

판단 생성

미팅 원문에서 딜별 귀속과 성사 확률을 만든다

영업 · 계약관리

상태 허브

위험 신호와 이력을 보고 다음 미팅을 제안한다

보고서 작성

실행 지원

원문과 하위 확정 보고서로 초안을 쓴다

일정관리

실행 지원

저장된 추천이 아직 유효한지 다시 판단한다

자료요약

실행 지원

문서를 구조화 요약하고 RAG 청크로 적재한다

판단과 제안을 만드는 두 에이전트

미팅분석

판단 생성

입력

미팅 원문

출력

딜별 귀속 · 13개 특성 · 성사 확률

사람 확인

확정할 때 저장된다

영업 · 계약관리

상태 허브

입력

위험 신호 7종 · 이력

출력

다음 미팅 제안 · 근거 브리핑

사람 확인

캘린더 승인

실행을 돕는 세 에이전트

보고서 작성

실행 지원

입력

원문 · 하위 확정 보고서

출력

작성 → 검토 → 수정 초안

사람 확인

확정 · 팀장 검토

일정관리

실행 지원

입력

저장된 추천 · 딜 상태

출력

유효 / 재생성 / 무시 판단

사람 확인

승인 · 거절

자료요약

실행 지원

입력

PDF · DOCX · 이미지

출력

구조화 요약 · RAG 청크

사람 확인

원문 대조

ML · OCR · Agent는 서로 다른 일을 한다



트리거와 작업 큐로 잇고, 사람이 닫는다

업무 트리거

- 자료 업로드
- 미팅 보고서 생성
- 보고서 확정
- 일정 등록
- 딜 단계 이동 외 3건

작업 큐

- agent_run 큐
- PostgreSQL 기반
- 부모 · 자식 실행
- 재시도 최대 2회
- lease 90초

에이전트

- 미팅 내용분석
- 보고서 작성
- 딜 특성 + ML 예측
- 계약관리 → 일정관리
- 브리핑 · 자료요약

사람

- 보고서 확정
- 추천 승인 · 일정 등록
- 팀장 검토 · 반려

사람의 확정이 다시 트리거가 되어 처음으로 돌아간다

전역 LLM Supervisor는 없다

무엇으로 잇는가

agent_run 큐

코드 dispatch

API 트리거

큐 규칙

부모 · 자식 실행 구조

재시도 최대 2회

lease 90초

DeepAgents 범위

보고서 작성 내부에서만

사용한다

전체 조율에는 쓰지 않는다

연결은 큐와 코드로 — 판단은 에이전트가, 확정은 사람이 한다

03

검증과 확장

제대로 동작하는지 어떻게 확인했는가

에이전트마다 다른 방법으로 검증했다

미팅분석	합성 골든셋 정답표 대조 + 딜 승산 ML 30회 반복
보고서 작성	합성 53건 LLM Judge 절대 평가 + 개선 전후 쌍대 비교
자료요약 · RAG	합성 문서 7개 · QRA 자동 골든셋 10건 LLM Judge
OCR	문서 200건 선정 필드 정답값 대조 · 1차와 최종 재시험 비교
영업 · 계약관리	[평가 방법 입력 예정]

30건 평균 89.8%, 근거 오류는 0건이었다

89.8%

전체 30건 평균
미팅 누적 깊이별 5개 시점

96.3%

미팅 1~5회 시점 평균
쌓일수록 점수는 내려간다

0건

없는 근거 인용 · 발언 왜곡
근거 없어 버려진 하이라이트도 0건

평가 방법

- | | | |
|----|----------------|------------------------|
| 01 | 합성 이력 구축 | 고객사 6곳 · 1~30회 5개 시점 |
| 02 | 시점별 정답 계산 | 주제 타임라인에서 그 시점의 정답만 |
| 03 | 도구 실제 실행 | DB 없이 실행 · RAG 호출까지 측정 |
| 04 | LLM 판정 + 코드 채점 | 판정만 LLM · 점수 산술은 코드 |

평가 데이터

- | | |
|--------|------------|
| 30 | 평가 케이스 |
| 180 | 확정 보고서 |
| 6 | 고객사 이력 |
| 1.7만 자 | 30회차 누적 입력 |

품질과 토큰 두 기준으로 B 구조를 골랐다

95.4점

B 구조 종합 점수

A 93.1 · C 94.0

46%

A 대비 토큰 사용량

10.01M → 4.57M

76.3점

B 월간 — 가장 낮은 유형

미팅 96.8 · 일일 95.6 · 주간 87.8

평가 방법

01 정답지 먼저 확정

LLM 생성 → 사람 검수 · 보정 후 고정

02 정답과 입력 분리

input.json ↔ golden.json

03 사실 단위 판정

충족 · 누락 · 왜곡 + 오류 출처 · 중대 오류

04 코드로 재검사

구조명 숨겨 위치 교차 · 인용 재검증

평가 데이터

53 평가 케이스

36 미팅 보고서

17 일일 12 · 주간 4 · 월간 1

27 가상 딜

C 구조는 입력 한도 초과로 월간 실패

정확도가 아니라 Brier와 FP로 Stacking_LR을 골랐다

0.1880

Stacking_LR Brier

7개 후보 중 1위 · 낮을수록 좋음

16.15

FP — 7개 후보 중 2위

최저는 LogisticRegression 16.09

+4.01%p

Accuracy 기준선 대비

69.58% → 73.60%

평가 방법

- | | | |
|-----------|-----------------------|----------------------------------|
| 01 | 항목 13개 선별 | 보고서에서 일관되게 뽑히는 항목 |
| 02 | 누수 차단 | 198개 입력 묶음 → Train 158 / Test 40 |
| 03 | 결측 마스킹 | 행마다 Unknown 4개 · 448건 × 10세트 |
| 04 | Brier · FP로 선택 | Train 안에서만 설정 · Test 제외 |

평가 데이터

- | | |
|--------------|---------------------------|
| 448 | 원본 딜 · Won 227 · Lost 221 |
| 13 | 입력 항목 (22개 중 선별) |
| 4,480 | 마스킹 후 학습 행 |
| 30회 | 반복 분할 평가 |

딜 귀속 84.7%, 특성 추출 74.8%가 다음 과제

84.7%

근거 · 딜 일치

94 / 111 구간

74.8%

딜 특성 필드 정확도

350 / 468 필드

82.6%

필수 사실 보존

38 / 46

0 / 36

13개 특성 전부 정답

가장 큰 과제


평가 방법

- 합성 미팅 12회 · 딜 36개로 만든 골든셋 (2026-08-31)
- AI가 의미를 검수한 결과이며 사람 판정이 아니다

13개 특성을 한 건도 빠짐없이 맞춘 사례는 36건 중 0건 — 가장 먼저 개선할 지점

딜 승산 모델은 Stacking으로 AUC 0.778까지 올랐다

■ 단계별 성능 — 공개 영문 B2B 448건 · 30회 반복 평균



+0.037

ROC-AUC 상승폭

0.7409 → 0.7783

0.1880

Brier 점수

0.2097 → 0.1880 (낮을수록 좋음)

미팅분석 수치를 읽을 때 유의할 점

합성 데이터

합성 미팅 12회 · 딜 36개

2026-08-31 골든셋

과거 코드 기준

사람 판정 아님

AI가 의미를 검수했다

사람 평가자가

채점한 결과가 아니다

영문 공개 데이터

딜 승산 ML은

공개 영문 B2B 448건 기준

한국어 실제 성능은 별도

실제 한국어 영업 데이터에서의 성능은 아직 측정하지 않았다

구조를 바꾸자 53건 모두 생성, 토큰은 54% 감소

47 → 53

유효 답안
53건 중

18 → 0

외부 재시도
생성 실패 6 → 0

-54.4%

생성 토큰
1,001만 → 457만

29 / 47

쌍대 우세
개선 전 우세 1건


평가 방법

- 루브릭 5개로 절대 채점하고, 순서를 익명 교차해 쌍대 비교했다
- 인용은 기계로 검증하고, 기간 보고서는 하위 확정본을 참조했다

실패하던 6건이 사라지고, 같은 결과를 절반 이하의 토큰으로 만든다

주간 · 월간 보고서 점수가 가장 크게 올랐다

■ 보고서 유형별 LLM Judge 점수 — 100점 만점 · 공통 43건



+14.6

주간 보고서 상승

72.50 → 87.08

-1.2

미팅 보고서 하락

97.74 → 96.57

보고서 수치를 읽을 때 유의할 점

표본이 작다

시나리오 1개

월간 보고서는 1건뿐

같은 모델이 채점

생성 모델과 Judge 모델이

동일하다 (gpt-5.6-luna)

떨어진 지표도 있다

미팅 보고서 점수 하락

사실 정확성 3.84 → 3.74

개선은 기간 보고서에 집중되었고, 미팅 보고서의 사실 정확성은 오히려 떨어졌다

[영업 · 계약관리 평가 결론 입력 예정]

[지표 입력 예정]

[지표 입력 예정]

[지표 입력 예정]


[지표 입력 예정]

[차트 또는 평가 도식 입력 예정]

[평가 데이터 · 방법 · 한계 입력 예정]

일정 추천은 보고서에 적힌 날짜에서 출발한다

현재 동작



승인한 뒤

일정관리 에이전트의 재판단

- 유효 / 재생성 / 무시 중 하나로 판단
- 날짜는 직접 만들지 않고 계약관리에 요청


지금 하지 않는 것

- 외부 캘린더 연동은 없다
- 반복 일정 패턴을 자동 규칙화하지 않는다

규칙 기반 자율 스케줄링이 아니라, 보고서에 적힌 날짜를 우선 쓰는 단순한 방식이다

문서요약 자동 평가 종합 점수는 0.846이다

■ 지표별 점수 (0-1 · 높을수록 좋음)



0.846

overall

자동 골든셋 10건 종합

0.828

completeness

가장 낮은 지표

합성 문서에서 골든셋을 만들어 자동 채점했다

평가 흐름

01 합성 문서 7개



02 QRA 자동 골든셋 10건



03 요약 6 · 검색 4 LLM Judge 채점

읽을 때 주의

- 요약 6건은 0.91–0.98 구간
- 사람 검수는 pending 상태
- 모두 합성 문서 기준 결과

조건부 PNG 재시도로 핵심 문서 일치율 98.8%

98.8%

핵심 구조화 문서

1,136 / 1,150 · +33.4%p

98.5%

계약서

197 / 200 · +73.5%p

98.5%

발주서


739 / 750 · +31.6%p

100%

견적서


200 / 200 · 1차부터 유지

문서 유형별 선정 필드 일치율 (%)




스캔 PDF만 골라 이미지 OCR로 다시 읽는다

고도화 3단계



요약은 고르게 높지만 검색 답변은 편차가 크다

■ 케이스별 overall 점수 (0-1) · 요약 6건 · 검색 4건



검색1 한 건이 0.25 — 최신 자료 대신 옛 계약서를 참조했다

RAG 답변 4건 중 1건은 옛 계약서 날짜를 답했다

검색1 — overall 0.25

질문	현재 기준 설치 예정일
기대한 답	2026-10-08 (추가 자료)
실제 답변	2026-09-24 (기존 계약서)

→ 최신 자료 대신 옛 계약서를 참조했다

읽을 때 주의

- 평가 스크립트의 검색은 단어 겹침 방식이다
- 운영은 키워드 + pgvector를 RRF로 병합하는 하이브리드 검색이다
- 보고서 RAG · 브리핑 근거는 별도 품질 평가가 없다

[실패와 개선 사례 1 결론 입력 예정]

처음 접근

무엇이 문제였나

어떻게 바꿨나

결과

[입력 예정]

[입력 예정]

[입력 예정]

[입력 예정]

[실패와 개선 사례 2 결론 입력 예정]

처음 접근

무엇이 문제였나

어떻게 바꿨나

결과

[입력 예정]

[입력 예정]

[입력 예정]

[입력 예정]

[보완점 결론 입력 예정]

한계 1

[영역 · 내용 · 영향 입력 예정]

한계 2

[영역 · 내용 · 영향 입력 예정]

한계 3

[영역 · 내용 · 영향 입력 예정]

[한 줄 정리 입력 예정]

다음 단계는 네 가지다

■ 향후 계획 — 현재 구현된 기능이 아니다

01

일정 에이전트 고도화

축적된 일정 데이터로
반복 업무 패턴을 규칙화해
Rule-based 추천으로 확장

02

ML 모델 성능 고도화

데이터와 모델 개선을 통한
예측 성능 향상

03

팀장 화면 개선

더 쉽고 빠른 업무 현황 확인을
위한 UI/UX 개선
가독성 · 현황 파악 · 접근성

04

매출 분석 기능 확장

계약금 중심 관리에서
매출 현황 · 추이 분석으로 확장

담당자의 머릿속을 조직의 기록으로 남긴다

고객 관계 맥락

회사 · 담당자 · 부서

접점 히스토리

일정 · 활동 · 보고서

고객의 실제 발언

원문 · STT · 첨부

발언의 대상 · 범위

공통 · 딜별 + 근거 ID

구매 판단 신호

권한 · 경쟁사 등 13개 특성

딜 진행 맥락

단계 · 금액 · 계약 · 납기

기록이 남으면 사람이 바뀌어도 맥락은 남는다

과거 맥락

이전 확정 보고서

이슈 · 불만 맥락

불만 · 긴급도 · 처리

위험과 다음 행동

만료 · 지연 · 추천

문서 지식

원문 추출 · 요약 · RAG

판단의 책임 · 이력

작성자 · revision · 승인


AI는 구조화 · 요약 · 제안까지

확정은 사람의 승인으로


Q & A

감사합니다 · Thank You

모든 데이터는 딜을 중심으로 연결된다



7주 동안 기획에서 배포 검증까지 진행했다



딥 승산 모델 단계별 성능 상세

단계	Accuracy	ROC-AUC	Brier
RF 기준선	0.6958	0.7409	0.2097
RF 튜닝	0.7338	0.7756	—
Stacking_LR (최종)	0.7360	0.7783	0.1880

Brier는 낮을수록 좋다 · RF 튜닝 단계의 Brier 값은 보고서에 기록되지 않았다

보고서 유형별 LLM Judge 점수 상세

보고서 유형	개선 전	개선 후
미팅 보고서	97.74	96.57
일일 업무보고	86.88	95.16
주간 업무보고	72.50	87.08
월간 업무보고	66.25	76.25

100점 만점 · 공통 43건 · 생성 모델과 Judge 모델이 동일하며 시나리오는 1개, 월간 보고서는 1건이다

OCR 고도화 전후 문서별 상세

대상 (각 50건)	1차 테스트	최종 테스트	변화
견적서	200 / 200 = 100.0%	200 / 200 = 100.0%	0.0%p
계약서	50 / 200 = 25.0%	197 / 200 = 98.5%	+73.5%p
발주서	502 / 750 = 66.9%	739 / 750 = 98.5%	+31.6%p
상품설명서	42 / 50 = 84.0%	43 / 50 = 86.0%	+2.0%p

핵심 구조화 문서(견적서 · 계약서 · 발주서) 합산 — $752 / 1,150 = 65.4\% \rightarrow 1,136 / 1,150 = 98.8\%$ (+33.4%p)

정규화한 정답값이 OCR 본문에 포함되면 일치로 판정 · 웹 스타트 처리 시간은 명함 2.24초 · PDF 1.23초 (각 5회, 별도 측정)

본문에 쓰인 근거 자료

- 프로젝트 기획서 (2026-08)
- Grand View Research (2026)
- KISDI 2026 · 원자료 Gartner 2025
- 환율 2026-09-15 기준 1,347.8원
- 각 사 공식 제품 페이지 (2026-09-15 확인)
- SalesLuv 구현 코드 (develop, 2026-09-17)
- 미팅 내용분석 구조 보고서 (2026-08-31 골든셋)
- 머신러닝 · 딥러닝 학습결과서 (30회 평균)
- docs/eval/01_보고서작성에이전트 (2026-09-08)
- docs/document-summary-evaluation.md
- output/evals/document-summary-rageval
- OCR 고도화 전후 최종 결과보고서 (2026-09-17)

평가용 데이터는 모두 합성 데이터이며 실제 고객 · 영업 데이터를 사용하지 않았다