



영업의 흐름을 연결하는 멀티에이전트

CRM(고객관계관리)

SKN30 1Team CassTerra

2026. 09. 18(Fri) 14:00

천성배 · 정주애 · 박제섭 · 박지유

멘토 : 노원재

# 세 파트로 설명합니다

---

## 01

### 문제 정의

왜 이 문제를 선택했는가?

---

시장현황 · 영업활동 6단계 흐름  
기존 CRM 활용 · 암묵지  
기존 CRM 문제 · 문제정의 ·  
해결책 · 경쟁사 현황 · 기대효과

## 02

### 설계와 구현

무엇을 어떻게 만들었는가?

---

Multi-Agent Flow · 시연영상

## 03

### 검증과 확장

근거에 맞게 동작하고 있는가?

---

에이전트별 평가 · 일정 에이전트  
실패와 개선 · 향후 계획 · 결론

# 01

---

## 문제 정의

왜 이문제를 선택했는가?

# 고객관리를 위한 핵심도구로 성장하는 중입니다

## 국내 CRM 시장 현황

### CRM 시장

2025  
약 2조 5,084억원

2026–2033 CAGR 10.3%

2033  
약 5조 4,595억원

### SaaS 시장(클라우드 애플리케이션)

2025  
약 2조 1,295억원

2025–2029 CAGR 17.1%

2029  
약 4조 164억원

출처: Grand View Research (2026 업데이트), KISDI (2026; 원자료 Gartner 2025)

\*국내 의료기기 기업 6,661개 | 영업·판매직무 종사자 20,036명 <출처: Gartner 2025분석>

# 영업활동의 6단계 흐름



# 기존 영업도메인 CRM의 활용



고객, 활동, 계약, 매출 정보를 저장하는 기능

그러나 고객의 우려, 다음 행동의 이유, 담당자 판단 기준은 기록에서 빠질 수 있습니다.



기록을 **다시 읽어도 영업맥락을 다시 찾아야** 합니다.

# 기존 영업도메인 CRM의 문제점

- 01**    **영업정보 분산**       고객 . 문서 . 미팅기록을 여러화면에서 다시 찾아야 합니다
- 02**    **영업흐름 단절**       이전 대화와 현재 딜의 연결이유가 남지 않습니다
- 03**    **영업판단 공백**       다음 행동의 근거를 담당자가 다시 해석해야 합니다
- 04**    **영업정보 소실**       담당자 변경시 관계와 노하우가 함께 사라집니다

# “암묵지”가 도대체 뭐예요?

---



문서화하기 어렵지만 반복되는 상황에서 작동하는 판단 기준

예 : 표면으로 드러나지 않는 실권자 정보

# 결국 문제는 암묵지

---


“ 고객 맥락과 영업 노하우는  
개인의 암묵지로만 쌓인다 ”

# 기존 영업도메인 CRM의 해결책

## 영업 특화 CRM 시장: 진입 판단

### 1 성장 배경

국내 CRM·SaaS 지출 확대



### 2 시장 통계의 한계



'영업 CRM 단독' 공개 표준  
시장규모 미확인



### 3 초기 진입 방향

문서·견적·계약·납품이 복잡한 B2B 영업팀



핵심 차별화

문서 근거 검색 · 고객/딜/계약 연결 · 담당자 승인 후 반영

공개 기능 기준 경쟁 환경

HubSpot Breeze

핑거세일즈 AI CRM

세일즈인사이트 CRM

세일즈랩: 인접 대체재

출처: 각 사 공식 제품·서비스 페이지 (2026-09-15 확인)

단순히 고객정보를 저장하는 것을 넘어, 미팅 전 브리핑부터 AI보고서, 다음 행동추천까지 영업의 맥락을 연결합니다.

# 국내 B2B CRM 경쟁현황

| 공통 기능군                                  | 세일즈맵 | 핑거세일즈 | 세일즈인사이트 | SalesLuv |
|-----------------------------------------|------|-------|---------|----------|
| 고객·거래처·담당자 관리                           | ●    | ●     | ●       | ●        |
| 잠재고객·영업활동 기록                            | ●    | ●     | ●       | △        |
| 고객 히스토리·영업기회                            | ●    | △     | ●       | ●        |
| 영업 파이프라인·딜 관리                           | ●    | ●     | ●       | ●        |
| 영업 실적·매출 분석                             | ●    | ●     | △       | ●        |
| 계약·청구·수금·입금                             | △    | △     | ●       | △        |
| 고객지원·팀 협업                               | △    | ●     | △       | ●        |
| ✦ AI 자동화<br>미팅 분석·보고서 초안·자료 요약·다음 행동 추천 | ✕    | ✕     | ✕       | ●        |

● 제공   △ 일부 기능   ✕ 비교 기준상 AI 자동화 기능 없음

# 여러 정보탐색의 번거로움을 겪지 않습니다

## 효성요양병원 (울산 중구)

효성요양병원 (울산 중구) 설치 및 사용자 교육 · 9월 18일 (금) 11:00

제품교육

### AI 브리핑 ⓘ

🔄 새로고침

#### C/S 1건 — 전원 인가 시 간헐적 재부팅, 접지 보완 진행 중

전원 인가 시 하루 두세 차례 재부팅이 발생해 원인 파악 중이며, 현장 전압 측정 결과 접지가 분리되어 병원 시설팀과 보완 일정을 잡은 상태입니다. [🔗](#) 설치·교육 전에 접지 보완 완료 여부와 재부팅 재발 여부를 확인해야 합니다.

- 병원 시설팀의 접지 보완 일정과 완료 여부를 확인한다.
- 보완 후 전원 인가 테스트 및 재부팅 재발 여부를 확인한다.
- 조치 결과와 후속 대응 담당자를 고객에게 설명한다.

#### LR1000 발주 확정 건, 설치·사용자 교육 단계 확인 필요

LR1000 발주 진행 건은 발주 확정 상태이며 계약금액은 4,760,000원, 납품 예정일은 2026년 8월 19일입니다. 이번 미팅이 설치 및 사용자 교육 일정이므로 실제 납품·설치 완료 상태와 교육 범위를 확인해야 합니다.

- 납품 및 설치 완료 여부를 확인한다.
- 사용자 교육 대상자와 교육 범위를 확정한다.
- 검수 완료 및 대금 지급 절차를 안내·확인한다.

| 9월 18일 (금) 일일 업무 보고서 |        |       |                |
|----------------------|--------|-------|----------------|
| 작성자                  | 김진남    | 부서명   | 영업1팀           |
| 직책                   | 팀원     | 작성일   | 2026.09.18 (금) |
| 회사명                  | 플레이데이터 | 보고 대상 | 전성배            |

오늘 한 일

2026-09-18 의료법인춘천서인병원에서 레이저 장비 교체 검토와 비교 견적에 관한 미팅을 진행했습니다. 방문했습니다. 기존 레이저 장비의 사용 상태와 교체 우선순위를 확인하고, LR1000-LR2000의 가격과 구성 차이를 설명했습니다. LR2000의 상태 확인-설정 확인-사용 준비 흐름을 짧게 시연했습니다.

거래처별 결과

의료법인춘천서인병원

기존 레이저 장비는 계속 사용 중이며 크게 고장 난 상태는 아니지만, 고객은 전원을 켤 때마다 상태를 확인하게 되고 예전만큼 안심되지 않는다고 했습니다. 당장 장비를 멈출 상황은 아니며, 다른 장비도 검토해야 하고 한 번에 모두 구매할 여유가 없어 레이저를 조금 더 사용할 수도 있다고 했습니다. 레이저 교체 우선순위는 미확정입니다.

LR1000은 450만원, LR2000은 520만원, LR 프로는 600만원으로 안내했습니다. 고객은 LR1000과 LR2000의 모델별 가격 차이를 함께 적고, 병원에 필요한 항목과 불필요한 항목, 호환 구성-제외 구성-설치 전 확인 사항을 구분해 달라고 요청했습니다. 액세서리나 추가 비용이 나중에 별도로 붙는 방식은 곤란하다고 했으며, 필요한 프로브 액세서리 부품은 호환성 확인 전에는 임의로 포함하지 말고 선택 항목으로 표시해 달라고 했습니다. LR2000의 화면은 어렵지 않다는 반응이 있었지만, 실제 설치 시 기존 장비와 맞지 않으면 추가 비용이 발생할 수 있다는 우려가 있었습니다.

고객은 즉시 구매를 결정하지 않고 실장과 다른 장비 견적을 함께 비교해 검토하기로 했습니다. LR1000-LR2000 비교 견적을 원장님과 실장님께 보내고 모델별 차이, 호환 구성, 제외 구성, 설치 전 확인 사항을 구분해 정리하기로 했습니다. 고객은 견적 수신 후 검토하기로 했습니다.

미완료-문제

교체 우선순위와 즉시 구매 여부는 결정되지 않았습니다. 실제 설치 시 기존 장비와의 호환 여부와 추가 비용은 확인되지 않았습니다. 최종 견적의 설치 조건, 필요한 구성과 제외 구성, 부가세 포함 여부, 기존

# 보고서의 성격에 따라 작성기준은 달라집니다

## 미팅보고서

개별 미팅의 사실 기록

작성 순서

**미팅 목적 → 논의 내용 → 고객 요구 → 합의사항 → 후속조치**

고객의 발언·요청·합의사항을 근거로 작성합니다.  
주관적인 감상 표현은 피합니다.

## 일일업무보고서

당일 활동과 결과 집계

작성 순서

**오늘 한 일 → 거래처별 결과 → 미완료·문제 → 다음 업무**

미팅 내용을 그대로 복사하지 않고,  
거래처별 결과와 후속조치를 요약합니다.

## 주간업무보고서

목표 대비 성과 분석

작성 순서

**목표 → 실적 → 차이 → 원인 → 다음 주 조치**

목표와 실적의 차이, 발생 원인,  
해결 행동을 중심으로 작성합니다.

## 월간업무보고서

성과와 의사결정

작성 순서

**성과 → 원인 → 문제 → 개선안 → 다음 달 계획**

다음 달 우선순위와 지원·승인이 필요한  
내용을 중심으로 작성합니다.

김 김진남

# 영업문서를 요약하여 한눈에 주요 사항을 알아봅니다

원본 문서

견적서\_14.pdf

견적서\_14

SL-DC-2026-0121

견적서 PDF

품목별 금액은 LP1000 프로브 2,470,000원, LP1500 프로브 1,595,000원, LR-CORE2 액세서리 24,000,000원, LP200 부품 1,440,000원, LR1000 시스템 9,000,000원, LR-CORE1 액세서리 8,400,000원입니다.

견적은 가격(VAT IN) 기준이며, 유효기간은 견적일로부터 30일입니다.

영업 참고사항

고객사 더봄병원에 레이저장비와 프로브, 액세서리, 부품을 함께 제안한 거래 견적입니다.

총 견적금액은 부가세 포함 46,905,000원이며, 금액 비중이 가장 큰 품목은 LR-CORE2 액세서리 5개, 24,000,000원입니다.

견적서에는 기본 소모품, 추가 구성, 운영 보조, 교체용, 운영 구성, 확장 구성 등 품목별 용도가 기재되어 있습니다.

리스크

1

견적 유효기간이 견적일로부터 30일로 제한되어 있으므로 유효기간 확인이 필요합니다.

2

문서에는 납기, 결제조건, 설치조건 및 보증조건이 기재되어 있지 않습니다.

원본 문서

견적서\_14.pdf

견적서

더봄병원 귀하

견적일자 : 2026년 9월 4일  
유효기간 : 견적일로부터 30일  
견적번호 : SL-260904-014

당사와의 거래에 감사드리며, 다음과 같이 요청하신 레이저장비 견적서를 제출합니다. 가격(VAT IN) 기준 견적입니다.

견적합계 : 46,905,000원정 (₩ 46,905,000 부가세포함)

| 순위 | 품명       | 규격   | 단위 | 수량 | 단가        | 금액         | 비고     |
|----|----------|------|----|----|-----------|------------|--------|
| 1  | LP1000   | 프로브  | EA | 19 | 130,000   | 2,470,000  | 기본 소모품 |
| 2  | LP1500   | 프로브  | EA | 11 | 145,000   | 1,595,000  | 추가 구성  |
| 3  | LR-CORE2 | 액세서리 | EA | 5  | 4,800,000 | 24,000,000 | 운영 보조  |
| 4  | LP200    | 부품   | EA | 6  | 240,000   | 1,440,000  | 교체용    |
| 5  | LR1000   | 시스템  | EA | 2  | 4,500,000 | 9,000,000  | 운영 구성  |
| 6  | LR-CORE1 | 액세서리 | EA | 2  | 4,200,000 | 8,400,000  | 확장 구성  |
|    |          |      |    |    |           |            |        |
|    |          |      |    |    |           |            |        |
|    |          |      |    |    |           |            |        |
|    |          |      |    |    |           |            |        |
|    |          |      |    |    |           |            |        |
|    | 소계       |      |    |    |           | 46,905,000 | 부가세포함  |
|    | 합계       |      |    |    |           | 46,905,000 |        |

# SalesLuv을 사용하면 이렇게 달라집니다

## 기존 CRM

- 저번에 거래처 사장님이랑 무슨이야기를 나눴지?
- 신제품 자료는 또 어디있지?
- 아 어찌지.. 많은 이야기를 나눴는데 다 기억이 안나!!
- 다음 미팅은 또 언제로 잡아야 하나..

## SalesLuv 사용자라면

- ✓ 아 저번 미팅때 다음 방문할때 신제품 소개해달라고 하셨네!!
- ✓ 브리핑에 참고자료에 브로셔가 연결되니 바로 볼 수 있어!
- ✓ 바쁘다 바빠! 녹음파일만 딱 넣으니 미팅보고서 바로 만들어주네?!
- ✓ 만들어준 보고서 승인하니까, 다음 미팅일정도 추천해줘서 너무 편해

# 02

---

## 설계와 구현

무엇을 어떻게 만들었는가?


## 시연 영상

영업의 맥락을 유지하고, 암묵지를 자산으로 보존합니다




# 전체 멀티에이전트 흐름

5개 에이전트가 영업 업무를 나눠 처리합니다.



# 01 내용 분석 에이전트

같은 분석 결과를 보고서 작성과 딜별 계약가능성 분류에 활용합니다.



# 내용 분석 Agent 상세 설명

미팅 내용을 정리해 보고서 작성과 계약가능성 분류에 전달합니다.



# 논문의 Random Forest를 기준 모델로 정했습니다

공개 B2B 영업 데이터로 SalesLuv의 입력 조건에 맞는 기준 모델을 학습했습니다.

논문 p.19 · Table 3

Table 3: The CA and AUC average performance on the business data set.

| <i>ML model</i> | <i>CA</i> | <i>AUC</i> |
|-----------------|-----------|------------|
| RF              | 0.782     | 0.85       |
| NB              | 0.777     | 0.83       |
| DT              | 0.742     | 0.76       |
| NN              | 0.702     | 0.70       |
| SVM             | 0.567     | 0.59       |

5개 모델 중 Accuracy·AUC 최고

448건

익명화된 실제 B2B 영업기회

논문에서 참고

Random Forest · 8:2 분할 · 30회 반복

우리 기준 모델

13개 특성 + 결측 마스킹 + 그룹 분리

우리 조건으로 직접 학습한 RF와 개선 모델을 비교

참고 · Bohanec et al. (2017), Table 3 · 저자 공개 원고 p.19 · DOI: [10.1016/j.eswa.2016.11.010](https://doi.org/10.1016/j.eswa.2016.11.010)

# 서비스에 맞춰 22개 컬럼을 13개로 줄였습니다

미팅에서 확인할 수 있고 사용자·조직이 달라도 의미가 같은 항목을 골랐습니다.

22개 입력 → 13개 공통 영업 특성

## 선정한 항목 · 미팅·CRM에서 확인할 수 있는 정보

|       |                                |
|-------|--------------------------------|
| 구매 준비 | 의사결정 권한 · 구매부서 · 예산 · 입찰 · RFP |
| 관계·거래 | 유입 경로 · 고객 관계 · 교차판매 · 거래 유형   |
| 상황·의향 | 경쟁사 · 긍정 구매 표현 · 계약 범위 · 요구 정의 |

## 제외한 9개

조직마다 의미가 다른 정보

상품 코드 · 담당자 코드 · 고객관리 유형

확인하기 어려운 정보: 전략적 중요도 · 상향판매

이번 범위 제외: 고객 규모 · 파트너십  
정보요청서(RFI) · 고객사 성장 상태

출처 · ML 학습결과서 §2.2 컬럼 선정 · 현재 13개 입력 항목

# 일부 정보가 없는 미팅을 마스킹으로 재현했습니다

마스킹은 학습·평가용입니다. 서비스에서는 확인되지 않은 값만 Unknown으로 전달합니다.

13개 중 약 30% 누락을 가정 → 행마다 총 4개를 Unknown으로

## 원본 예시

| 권한   | 경쟁사     | 구매부서 | 예산  | 입찰 | RFP | 구매표현 | 유입      | 고객관계 | 범위    | 교차판매 | 거래유형    | 요구정의 |
|------|---------|------|-----|----|-----|------|---------|------|-------|------|---------|------|
| High | Unknown | Yes  | Yes | No | Yes | Yes  | Unknown | New  | Clear | No   | Project | Yes  |

## 마스킹 예시 · 기존 Unknown 2개 보존 + 2개 추가

|      |         |     |         |    |     |     |         |     |         |    |         |     |
|------|---------|-----|---------|----|-----|-----|---------|-----|---------|----|---------|-----|
| High | Unknown | Yes | Unknown | No | Yes | Yes | Unknown | New | Unknown | No | Project | Yes |
|------|---------|-----|---------|----|-----|-----|---------|-----|---------|----|---------|-----|

## 거래마다 누락 위치를 바꾼 10가지 버전

Unknown = 미확인 / No = 없음 확인

출처 · ML 학습결과서 §§2.3-2.4 · 화면의 값은 마스킹 설명용 예시

# 같은 거래가 학습과 평가에 섞이지 않도록 나눴습니다

마스킹 전 13개 입력이 같은 거래는 하나로 묶어 학습 또는 평가에만 사용했습니다.

**원본 448건**

동일 입력끼리 묶기

**198개 그룹**

한 거래의 마스킹 10개도  
같은 그룹에 유지



**학습 · 그룹 80%**

**158개 그룹**

Train 내부에서만 튜닝 · 그룹 5-Fold 검증

**평가 · 그룹 20%**

**40개 그룹**

학습·파라미터 선택에서 제외한 Test로 비교

**30회 반복 분할 · 모든 후보에 같은 분할과 마스킹 적용**

출처 · ML 학습결과서 §§2.5, 3.3 · 8:2는 거래 수가 아닌 그룹 수 기준


# 네 모델의 예측을 모아 최종 확률을 계산합니다

FP 위험을 주요 선정 조건에 반영하고 예측 성능과 확률 오차를 함께 비교했습니다.

## 01 개별 모델의 예측

## 02 예측 확률 결합

## 03 최종 분류




**FP 중점 관리 | 실제 Lost를 Won으로 오판하는 '낙관적 예측'**

선정 · 튜닝 RF보다 Brier·Accuracy·AUC·FP·FPR이 나빠지지 않은 후보 중 최저 Brier | 출처: ML 학습결과서 §4.2

## 02 보고서 작성 에이전트

미팅·기간보고서를 작성하고 사용자 승인 후 저장합니다.



# 보고서 작성 Agent 상세 설명

미팅은 딜별로, 기간은 총괄로 작성한 뒤 동일한 승인·저장 과정을 거칩니다.



# 보고서별 작성 가이드

## 미팅보고서

개별 미팅의 사실 기록

작성 순서

미팅 목적 → 논의 내용 → 고객 요구 → 합의사항 → 후속조치

고객의 발언·요청·합의사항을 근거로 작성합니다.  
주관적인 감상 표현은 피합니다.

## 일일업무보고서

당일 활동과 결과 집계

작성 순서

오늘 한 일 → 거래처별 결과 → 미완료·문제 → 다음 업무

미팅 내용을 그대로 복사하지 않고,  
거래처별 결과와 후속조치를 요약합니다.

## 주간업무보고서

목표 대비 성과 분석

작성 순서

목표 → 실적 → 차이 → 원인 → 다음 주 조치

목표와 실적의 차이, 발생 원인,  
해결 행동을 중심으로 작성합니다.

## 월간업무보고서

성과와 의사결정

작성 순서


성과 → 원인 → 문제 → 개선안 → 다음 달 계획

다음 달 우선순위와 지원·승인이 필요한  
내용을 중심으로 작성합니다.

참고자료: 실제 영업사원 천 모씨 제공자료

# 03 영업·계약관리 에이전트

확정 보고서와 영업·계약·C/S 활동을 바탕으로 다음 미팅을 제안합니다.




# 영업·계약관리 Agent 상세 설명

확정 보고서와 영업 활동을 바탕으로 다음 미팅을 제안합니다.



## 04 일정관리 에이전트

일정이 겹치면 영업·계약관리 에이전트에 다음 후보 조율을 요청합니다.




# 일정관리 Agent 상세 설명

일정이 겹치면 후보를 조율하고 사용자 승인 후 브리핑을 만듭니다.



# 05 미팅 전 브리핑

승인한 일정과 보고서·자료 RAG 조회 결과로 브리핑을 만듭니다.




# 미팅 전 브리핑 상세 설명

승인한 일정과 보고서·자료요약 Agent RAG의 조회 결과를 정리합니다.




## 06 자료요약 에이전트

OCR로 문서 속 텍스트를 읽어 요약하고 필요한 내용을 조회합니다.



# 자료요약 Agent 상세 설명

스캔·이미지 문서는 OCR로 텍스트를 추출해 요약합니다.



# 03

---

## 검증과 확장

근거에 맞게 제대로 동작하고 있는가?

# 평가 설계의 두 가지 질문

01

**데이터 부족**

개인정보 · 민감정보

02

**매번 달라지는 응답**

동일 입력, 다른 결과

03

**평가 편향**

길이 · 순서 · 자기 선호

골든셋 제작

**LLM이 골든셋을 만들어도 될까?**

결과 평가

**LLM에게 평가를 맡겨도 될까?**

# 평가 지표를 정한 뒤 원문을 만들었습니다

실제 데이터 부족    합성 시나리오로 평가셋 구성



평가에 쓸 사실을 먼저 확정

정답은 입력에서 분리

# 사람이 검수해 평가 기준을 확정합니다

LLM이 구성한 초안

## 사람 검수 · 기준 확정

금액 · 조건 · 상태 · 기한



에이전트  
**원문**



평가자용  
**골든**

필수 사실 · 금지 주장 · 근거

사실·조건 검수

정보 분리

평가 전 기준 고정

# G-Eval: 기준과 절차에 따라 평가

## G-EVAL: NLG Evaluation using GPT-4 with Better Human Alignment

Yang Liu Dan Iter Yichong Xu  
Shuohang Wang Ruochen Xu Chenguang Zhu

Microsoft Azure AI  
yulin10@microsoft.com

### Abstract

The quality of texts generated by natural language generation (NLG) systems is hard to measure automatically. Conventional reference-based metrics, such as BLEU and ROUGE, have been shown to have relatively low correlation with human judgments, especially for tasks that require creativity and diversity. Recent studies suggest using large language models (LLMs) as reference-free metrics for NLG evaluation, which have the benefit of being applicable to new tasks that lack human references. However, these LLM-based evaluators still have lower human correspondence than medium-size neural evaluators. In this work, we present G-EVAL, a framework of using large language models with chain-of-thoughts (CoT) and a form-filling paradigm, to assess the quality of NLG outputs. We experiment with two generation tasks, text summarization and dialogue generation. We show that G-EVAL with GPT-4 as the backbone model achieves a Spearman correlation of 0.511 with human on summarization task, outperforming all previous methods by a large margin. We also propose analysis on the behavior of LLM-based evaluators, and highlight the potential concern of LLM-based evaluators having a bias towards the LLM-generated texts.<sup>1</sup>

### 1 Introduction

Evaluating the quality of natural language generation systems is a challenging problem even when large language models can generate high-quality and diverse texts that are often indistinguishable from human-written texts (Ouyang et al., 2022). Traditional automatic metrics, such as BLEU (Papineni et al., 2002), ROUGE (Lin, 2004), and METEOR (Banerjee and Lavie, 2005), are widely used for NLG evaluation, but they have been shown to have relatively low correlation with human judgments, especially for open-ended generation tasks.

<sup>1</sup><https://github.com/nlpyang/geval>

논문 원문 · 1페이지

## 논문의 평가 방식

평가 기준 제시 → LLM이 평가 단계 생성  
단계에 따라 판단 → 정해진 형식으로 채점  
요약·대화 과제에서 사람 평가와 비교

## SalesLuv에 적용

## 정해진 기준과 근거로 평가

출력 + 골든 + 항목별 기준

충족·누락·왜곡 판정 + 원문 근거

Liu et al. · EMNLP 2023 · G-Eval · [\(원문 1페이지\)](#)

# MT-Bench: LLM 평가의 신뢰성과 편향

## Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena

Lianmin Zheng<sup>1\*</sup> Wei-Lin Chiang<sup>1\*</sup> Ying Sheng<sup>1\*</sup> Siyuan Zhuang<sup>1</sup>

Zhanghao Wu<sup>1</sup> Yonghao Zhuang<sup>3</sup> Zi Lin<sup>2</sup> Zhuohan Li<sup>1</sup> Dacheng Li<sup>1,3</sup>

Eric P. Xing<sup>1,5</sup> Hao Zhang<sup>1,2</sup> Joseph E. Gonzalez<sup>1</sup> Ion Stoica<sup>1</sup>

<sup>1</sup> UC Berkeley <sup>2</sup> UC San Diego <sup>3</sup> Carnegie Mellon University <sup>4</sup> Stanford <sup>5</sup> MBZUAI

### Abstract

Evaluating large language model (LLM) based chat assistants is challenging due to their broad capabilities and the inadequacy of existing benchmarks in measuring human preferences. To address this, we explore using strong LLMs as judges to evaluate these models on more open-ended questions. We examine the usage and limitations of LLM-as-a-judge, including position, verbosity, and self-enhancement biases, as well as limited reasoning ability, and propose solutions to mitigate some of them. We then verify the agreement between LLM judges and human preferences by introducing two benchmarks: MT-bench, a multi-turn question set; and Chatbot Arena, a crowdsourced battle platform. Our results reveal that strong LLM judges like GPT-4 can match both controlled and crowdsourced human preferences well, achieving over 80% agreement, the same level of agreement between humans. Hence, LLM-as-a-judge is a scalable and explainable way to approximate human preferences, which are otherwise very expensive to obtain. Additionally, we show our benchmark and traditional benchmarks complement each other by evaluating several variants of LLaMA and Vicuna. The MT-bench questions, 3K expert votes, and 30K conversations with human preferences are publicly available at [https://github.com/lm-sys/FastChat/tree/main/fastchat/llm\\_judge](https://github.com/lm-sys/FastChat/tree/main/fastchat/llm_judge).

### 1 Introduction

There has been a proliferation of LLM-based chat assistants (chatbots) that leverage supervised instruction fine-tuning and reinforcement learning with human feedback (RLHF) to unlock new instruction following and conversational abilities [13, 2, 30, 8, 52, 48, 14]. Once aligned with humans, these chat models are strongly preferred by human users over the original, unaligned models on which they are built. However, the heightened user preference does not always correspond to improved scores on traditional LLM benchmarks – benchmarks like MMLU [19] and HELM [23] cannot effectively tell the difference between these aligned models and the base models. This phenomenon suggests that there is a fundamental discrepancy between user perceptions of the usefulness of chatbots and the criteria adopted by conventional benchmarks.

We argue that this discrepancy primarily arises due to existing evaluation that only measures LLMs' core capability on a confined set of tasks (e.g., multi-choice knowledge or retrieval questions), without adequately assessing its alignment with human preference in open-ended tasks, such as the ability to accurately adhere to instructions in multi-turn dialogues. As a demonstration, we show

\*Joint first authors. This paper is an extended version of our earlier blog post [8].

논문 원문 · 1페이지

논문이 확인한 점

사람 평가와의 일치도 검토

위치·길이·자기 선호 편향 분석

응답 순서 교환 등 완화 방법 제안

보고서 A/B 비교에 적

익명화 · 순서 교환 · 불일치 기록

같은 출력 쌍을 X/Y ↔ Y/X로 재평가

판정이 다르면 '검토 필요'로 보존

Zheng et al. · NeurIPS 2023 · Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena · ([원문 1페이지](#))

# 의미는 LLM, 구조는 코드

## LLM-as-a-Judge

### 의미 판정

사실 · 맥락 · 후속 행동

판정 + 근거

+

## 코드 기반 검사

### 구조 검사

형식 · 근거 ID · 점수 계산

검사 + 오류 기록

판정과 근거를 함께 기록

# 보고서 골든셋: 연결된 4주 영업 시나리오

53건

평가 사례

27개

가상 딜

4주

연결 시나리오

미팅

36건



일일

12건



주간

4건



월간

1건

9개 회사·9명 고객의 가상 영업 활동

실제 고객 데이터 미사용 · 서로 연결된 사례이며 월간은 1건

# 보고서 골든셋: 사람이 정답을 확정합니다



---

입력  
원문 · 현재 시점 정보

분리 보관

---

골든  
필수 사실 · 금지 주장 · 근거

작성기에는 정답지와 미래 사실을 주지 않습니다

# 보고서 평가: 표현보다 사실이 맞는지

|         |                                   |    |
|---------|-----------------------------------|----|
| 사실 정확성  | <div><div></div></div>            | 40 |
| 필수 내용   | <div><div></div><div></div></div> | 20 |
| 목적·구성   | <div><div></div><div></div></div> | 20 |
| 판단·후속조치 | <div><div></div><div></div></div> | 15 |
| 가독성     | <div><div></div><div></div></div> | 5  |

## 사실별 판정

충족 · 누락 · 왜곡

## 오류의 출처

작성 오류 / 이전 단계에서 넘어온 오류

## 중대 오류 별도 표시

다른 딜 혼입 · 계획을 완료로 변경

항목별 0~4점 판정 → 가중 합산 100점

출처 · salesluv-report-eval-v1/judge.md

# 평가 항목의 근거: 실무 보고서 작성 가이드

사실·필수 내용

60점

수치·조건 왜곡과 누락 확인

목적·후속조치

35점

유형별 보고 목적과 다음 행동 확인

가독성

5점

빠르게 읽고 업무에 쓸 수 있는가

실무 보고서 작성 가이드를 평가 항목에 반영  
사람이 검수한 정답·원문 인용으로 판정 근거 확인

# 보고서 평가: 근거와 점수를 다시 확인

|    |        |                       |
|----|--------|-----------------------|
| 01 | 정답 고정  | 사람 검수 후 평가 기준 확정      |
| 02 | 근거 인용  | 보고서 문장과 원문을 함께 기록     |
| 03 | 순서 교환  | A·B 이름을 숨기고 X/Y ↔ Y/X |
| 04 | 코드 재검사 | 점수 계산과 인용한 문장의 존재 확인  |

판정이 다르면 동점 대신 검토 필요

## 보고서 작성 방식: A · B · C

### A · 단계별 작성

미팅 → 일일 → 주간 → 월간

바로 아래 단계의  
실제 출력만 참조

### B · 단계별 + 작성 규칙

미팅 → 일일 → 주간 → 월간

같은 단계별 흐름에  
유형별 작성 순서를 추가

### C · 중간 단계 생략

확정 미팅 본문 → 기간 보고서

일일·주간·월간이  
확정 미팅 본문을 직접 참조

같은 시나리오로 품질·생성 성공·토큰을 비교

# A · B · C 비교: 토큰 · 품질 · 생성 성공률


A 단계별 작성

B 단계별 + 작성 규칙

C 미팅 본문 직접 참조


## 토큰 사용량

백만 · 낮을수록 좋음




## 보고서 품질

100점 · 높을수록 좋음



## 생성 성공률

% · 높을수록 좋음



각 방식의 별도 실행 결과 · 품질은 유효 채점 평균(A 44건 / B 52건 / C 51건)

토큰은 반환 사용량 합계(미반환 사용량 제외) · 출처: docs/eval 보고서 평가

# 최종 선택은 B입니다

B

단계별 작성  
+ 유형별 작성 규칙

## 품질

유효 채점 52건 · 100점 만점

95.43점

## 토큰 효율

단계별 작성 A 대비 반환 토큰 감소

54.4%↓

## 생성 안정성


미팅·일일·주간·월간 모두 생성

53/53건

# 브리핑 골든셋: 미팅 기록이 쌓이는 상황

6개 고객사 × 5개 시점 = 30사례

확정 보고서 180건 · 최신 3건 직접 조회 / 이전 기록은 RAG



표준 딜 4개

수량·납기·담당 변경

딜이 없는 고객

일상 기록에 섞인 핵심 정보

보고서·견적 충돌

모든 사안 종결

출처 · 미팅브리핑 평가 PPTX · 데이터셋 README

# 정보가 바뀌면 정답도 바뀝니다

골든셋의 정답도 평가 시점까지 확인된 정보에 맞춰 바뀝니다.

예시 · 고객의 장비 도입 요청이 달라지는 경우

처음 요청 · 4회차  
장비 20대 도입 희망

요청 변경 · 15회차  
장비 15대로 축소

다시 변경 · 22회차  
장비 12대로 축소

이후 정답: 20대

이후 정답: 15대

이후 정답: 12대

그 시점까지 확인된 최신 정보로 정답을 갱신

## 아직 발생 전

그 시점에는  
다룰 수 없음

## 진행 중

반드시 포함  
최근 3건 밖이면  
RAG 조회 필요

## 해결됨

다시 다루면 감점

## 값이 바뀜

해당 시점의  
최신 값만 사용

출처 · 미팅브리핑 평가 PPTX · 데이터셋 README

# 자료요약 에이전트 평가 & 결과

## 평가 대상

문서요약 에이전트  
OCR 에이전트

## 평가 방법

문서요약: 합성 문서 200개  
QRA 골든셋 10건 · LLM Judge  
OCR: 필드 일치율 비교

## 평가 결과

문서요약 overall 0.846  
핵심 문서 일치율 98.8%  
1,136 / 1,150

## 문서요약 평가

- overall 0.846 · completeness 0.828
- 요약 6건 0.91–0.98 · 사람 검수 pending
- 검색 4건 · 모두 합성 문서 기준

## OCR 평가

- 핵심 문서 65.4% → 98.8% (+33.4%p)
- 견적서 100.0% · 계약서·발주서 98.5%
- 명함 필드 94.8% · 자동 등록은 사람 검수 필요

핵심 구조화 문서(견적서 · 계약서 · 발주서) 합산 —  $752 / 1,150 = 65.4\% \rightarrow 1,136 / 1,150 = 98.8\% (+33.4\%p)$

정규화한 정답값이 OCR 본문에 포함되면 일치로 판정 · 웹 스타트 처리 시간은 명함 2.24초 · PDF 1.23초 (각 5회, 별도 측정)

# 향후계획(고도화)

영업 데이터 축적에 따른 딜 관리 : ML 성능 고도화

일정 추천의 우선순위 기준 개선

매출 분석과 고객 이슈 분석 기능 확장

C / S 대응 기능 기준 확장

팀장용 영업 현황과 검토 UI 개선

암묵지 항목과 확보 기준 확대

# 결론 : 암묵지를 영업맥락의 자산으로 기록

## 1 관계와 접점

**고객 관계 맥락** 회사·담당자·부서·방문·참여자

**접점 히스토리** 일정·장소·제품·활동·보고서 연결

## 3 리스크와 다음 행동

**과거 맥락** 이전 확정 보고서·완료 거래

**이슈·불만 맥락** 불만·긴급도·처리·변경·연결 조건

**위험과 다음 행동** 만료·지연·미해결 C/S·추천 행동

## 2 고객과 딜

**고객의 실제 발언** 미팅 원문·STT·첨부·보고서 본문

**발언의 대상과 범위** 공통·딜별·발언 위치·근거 ID

**구매 판단 신호** 권한·경쟁사·예산·RFP 등 13개 특성

**딜 진행 맥락** 단계·금액·제품·계약·납기·보증

## 4 근거와 책임

**문서 지식** 원문 추출·요약·페이지·섹션·RAG 출처

**판단의 책임·이력** 작성자·revision·승인·사유·source/AI ID

# Q & A

감사합니다

# 04



## 부록

# 트러블슈팅 1 : 보고서 에이전트 성능개선

토큰 소모는 줄이고, 보고서 완성도는 높여야 했다

**10,010,770**

기존 A 생성 토큰 합계  
전체 53건 실행

**72.50**

기존 A 주간 보고서 품질  
100점 만점

**66.25**

기존 A 월간 보고서 품질  
100점 만점

## 토큰 소모량

생성 · 재시도 과정의 토큰 부담  
입력 범위와 반복 호출의 효율화 필요

## 보고서 품질

기간보고서의 완성도 보완  
필수 정보 · 보고 목적 · 후속업무 정리 보완

개선 목표는 토큰 효율과 보고서 품질을 함께 올리는 것이었다

# 트러블슈팅 1 : 보고서 에이전트 성능개선

보고서 에이전트를 Deep Agents 기반으로 개량했다

01

## 입력 확정

보고서 종류와  
입력은 서버가 확정

02

## Supervisor

작업 위임  
검토 관리  
결과 선택

03

## Writer · Reviewer

### 유형별 Writer

작성 지침과 배정된 근거로 작성

### 공통 Reviewer

원자료와 초안 대조·수정 지적

04

## 결과

최대 1회 부분 수정

지적된 부분만 고친 초안

## 01 역할 분리

감독 · 작성 · 검토

## 02 지침 · 근거 분리

유형별 SKILL.md + 배정 근거

## 03 반복 수정 제한

검토 후 부분 수정 최대 1회

# 트러블슈팅 1 : 보고서 에이전트 성능개선

더 적은 토큰으로, 더 높은 종합 품질

토큰 소모량

**-54.36%**

전체 53건 실행 · 반환된 생성 토큰 합계

기존 A **10,010,770**

개선 B **4,568,617**

보고서 종합 품질

**+1.94점**

동일 43건 · LLM Judge 종합점수 / 100점

기존 A **93.23**

개선 B **95.17**

필수 내용 · 구성 · 후속업무 점수가 올랐다

평가 범위 작성 지침 · 실행 구조를 함께 개선한 A/B 비교 · 프레임워크 교체만의 효과는 아니다

보완 과제 종합점수는 올랐으나 미팅 평균 · 사실 정확성 항목은 하락했다

# 트러블슈팅 2 : OCR 성능개선

## ■ 고도화 흐름

### 1차

원본 PDF를 RunPod  
PDF OCR로 처리한다

기준 성능과 누락 필드 확인

### 조건부 재시도

한글 필수값 누락 또는 PDF OCR  
작업 실패일 때만 모든 페이지를  
PNG로 변환해 다시 읽는다

스캔 PDF의 텍스트 · 표 영역 복구

### 결과 선택

발주서 공급자 주소는 PDF 결  
과,나머지 선정 필드는  
PNG 결과를 쓴다

PNG 경로의 주소 하락 방지

## ■ 문서별 최종 경로

### 견적서

원본 PDF OCR 유지

### 계약서

한글 누락 시  
모든 페이지 PNG OCR

### 발주서

PNG OCR + 공급자  
주소만 PDF 결과 보존

### 상품설명서

PDF 작업 실패 문서만  
PNG OCR 재시도

## 트러블슈팅 2 : OCR 성능개선

**65.4% → 98.8%**

핵심 구조화 문서 선정 필드 일치율

1,136 / 1,150 · 견적서 · 계약서 · 발주서 150건

**+33.4%p**

1차 대비 개선 폭

견적서

**100.0% → 100.0%**

0.0%p · 200 / 200

계약서

**25.0% → 98.5%**

+73.5%p · 197 / 200

발주서

**66.9% → 98.5%**

+31.6%p · 739 / 750

상품설명서

**84.0% → 86.0%**

+2.0%p · 43 / 50

스캔 · 한글 누락 PDF만 PNG로 다시 읽고, 취약 필드는 PDF 결과를 보존했다

평가 범위 선정 필드 일치율 기준 · 문자 단위 전사 정확도 · CER / WER 미포함

남은 과제 상품설명서는 +2.0%p · 사양 값 자동 등록 정확도는 사람 검수 필요