



딜 승산 점수

데이터 전처리 및 AI 학습 모델

SalesLuv · Machine Learning Model Report

MODEL SUMMARY

Salvirt 입력 특성 22 개를 전체 후보군으로 두고, 현재 10 개로 1 차 테스트했다. 추후 확인 가능한 특성을 모두 적용하고 미확인 값은 Unknown 으로 처리한다. Logistic Regression 은 1 차 기준 모델이며 최종 모델은 튜닝 후 확정한다.

항목	결정
학습 문제	Won / Lost 이진 분류
학습 데이터	Salvirt B2B Sales Dataset
입력	22 개 후보 중 10 개로 1 차 테스트
전처리	중복 제거 · One-Hot Encoding · 그룹 분할
1 차 기준 모델	L2 Logistic Regression
출력	실험적 딜 승산 점수 0~100 점

검증 기준일 2026.08.17

1. 결정 요약

이 모델은 STT 나 미팅 원문을 직접 학습하는 NLP 모델이 아니다. 미팅 분석 Agent 가 원문과 CRM 정보에서 범주형 특성을 구성하고, ML 모델은 그 구조화된 값만 입력받는다. Salvirt 의 입력 특성 22 개를 전체 후보군으로 관리하며, 현재는 그중 10 개로 1 차 테스트했다.

운영 범위

출력 점수는 공개 데이터의 패턴을 기준으로 한 참고값이다. SalesLuv 환경의 실제 딜 성사 확률을 보장하지 않으며, 영업 단계·실제 계약의 자동 변경, 다른 Agent 실행, 담당자 평가에는 사용하지 않는다.

2. 학습 목적과 사용 범위

구분	내용
입력	현재 10 개 특성 / 향후 22 개 전체 입력 스키마
정답	영업 딜 성사 Won=1 / 취소 Lost=0
출력	딜 승산 점수
활용	고객 및 진행 딜 화면에 표시
제외	영업 단계·실제 계약 자동 변경 / 다른 Agent 실행 / 담당자 평가

3. 학습 데이터

Salvirt B2B Sales Dataset 을 사용한다. 대화 원문이 아니라 범주형 딜 조건과 최종 결과로 구성된 공개 B2B 영업 데이터다.

항목	확인 결과
원본 행	448 건
전체 컬럼	23 개
입력 특성	범주형 22 개
정답 컬럼	Status
빈값	0 건
중복 제거	83 건
중복 제거 후	365 건
Won	173 건
Lost	192 건

Won 173 건과 Lost 192 건으로 정답 비율이 비슷해 SMOTE, 임의 데이터 증강, class weight 는 적용하지 않는다.

4. 전체 입력 후보 22 개

Salvrit 데이터셋의 입력 특성 22 개를 전체 후보군으로 관리한다. 현재는 단일 미팅에서 비교적 추출 가능한 10 개로 1 차 테스트했으며, 추후 입력 스키마를 22 개 전체 컬럼으로 확장한다.

4.1 현재 1 차 테스트 특성 10 개

원본 컬럼	의미	원본 범주
Authority	의사결정권자 수준	High / Mid / Low
Competitors	경쟁사 검토 여부	Yes / No / Unknown
Purch_dept	구매부서 관여 여부	Yes / No / Unknown
Budgt_alloc	예산 확보 여부	Yes / No / Unknown
Forml_tend	공식 입찰 여부	Yes / No
RFI	정보요청서 진행 여부	Yes / No
RFP	제안요청서 진행 여부	Yes / No
Posit_statm	명시적인 긍정 구매 표현	Yes / No / Neutral
Scope	계약 범위 구체화 정도	Clear / Few questions / Low
Needs_def	고객 요구사항 구체화 정도	Yes / Poor / Info gathering / No

4.2 추가 적용 후보 12 개

컬럼	상태	컬럼	상태
Product	추후 적용	Seller	추후 적용
Comp_size	추후 적용	Partnership	추후 적용
Growth	추후 적용	Source	추후 적용
Client	추후 적용	Strat_deal	추후 적용
Cross_sale	추후 적용	Up_sale	추후 적용
Deal_type	추후 적용	Att_t_client	추후 적용

향후 처리 원칙

22 개 컬럼 중 미팅 또는 CRM 에서 해당 값을 확인할 수 있으면 실제 범주값을 입력하고, 확인되지 않으면 Unknown 으로 처리한다. Product·Seller 처럼 원본 익명 코드인 컬럼은 SalesLuv 범주 매핑 규칙을 정한 뒤 적용한다.

5. 데이터 전처리

1. 컬럼명과 문자열의 앞뒤 공백 정리
2. 정답을 Won=1, Lost=0 으로 변환
3. 23 개 컬럼 값이 모두 같은 완전 중복 행 83 건 제거
4. 1 차 테스트에서는 선정한 10 개 입력 특성만 유지
5. 향후 22 개 전체 컬럼에서 확인되지 않은 값은 Unknown 으로 처리
6. 범주형 특성을 One-Hot Encoding 으로 변환
7. 1 차 테스트는 10 개 특성 조합으로 그룹 지정하고, 확장 테스트는 22 개 조합으로 재설정

전처리 원칙

모든 입력이 범주형이므로 평균값 대체와 수치 정규화는 적용하지 않는다. 향후 22 개 입력 컬럼에서 확인할 수 없는 값은 No 로 가정하지 않고 Unknown 으로 통일하며, 학습·추론 단계에서 동일한 범주 체계를 사용한다.

Unknown 이 많은 팀은 점수 신뢰도가 낮을 수 있다는 한계를 남긴다.

6. 학습·검증 방식

행 단위 무작위 분할은 사용하지 않는다. 동일 특성 조합이 학습과 평가 데이터에 나뉘면 같은 입력을 미리 보게 되어 성능이 부풀려질 수 있기 때문이다.

검증 설계	적용 방식
그룹 기준	1 차 10 개 특성 조합이 같은 행을 하나의 그룹으로 설정
교차검증	StratifiedGroupKFold
반복	5-Fold × 시드 10 회
총 평가	50 개 fold 평균
고유 조합	1 차 10 개 기준 365 행에서 133 개 고유 조합

평가 지표

지표	의미	우선순위
ROC-AUC	승산이 높은 팀을 더 위에 배치하는 능력	높을수록 좋음
Brier Score	출력 점수와 실제 결과의 일치 정도	낮을수록 좋음
Accuracy	전체 예측 중 정답 비율	높을수록 좋음

점수의 순위와 확률적 품질을 보여주는 기능이므로 단일 Accuracy 보다 ROC-AUC 와 Brier Score 를 우선한다.

7. 10개 특성 기준 1차 모델 비교

현재 선정한 10개 특성으로 후보 모델을 기본 조건에서 간단히 비교한 초기 결과다. 22개 특성 확장과 튜닝 전의 기준값이며, 최종 모델 선정 결과가 아니다.

ROC-AUC 0.793 Logistic Regression	Brier Score 0.190 Logistic Regression	Accuracy 72.0% CatBoost
--	--	--------------------------------------

모델	ROC-AUC	Brier Score	Accuracy
Dummy 기준 모델	0.500	0.249	52.6%
One-Hot + Logistic Regression	0.793	0.190	71.0%
CatBoost	0.792	0.191	72.0%
One-Hot + MLP 신경망	0.785	0.197	70.6%

1차 비교에서는 Logistic Regression과 CatBoost의 성능 차이가 거의 없었다. 최종 모델은 특성 재검토와 튜닝 후 확정한다.

8. 1차 기준 모델

BASELINE MODEL

OneHotEncoder(handle_unknown="ignore") + LogisticRegression(C=0.1, L2)

CatBoost와 거의 같은 ROC-AUC를 보이면서 Brier Score는 더 좋다.

MLP 신경망보다 검증 성능이 높다.

현재 데이터 규모에 적합하다.

모델의 입력과 영향을 설명하기 쉽다.

추가 학습 인프라 없이 가볍게 운영할 수 있다.

적용 방향

현재 비교에서는 Logistic Regression을 1차 기준 모델로 우선 적용한다. 최종 모델은 입력 특성 재검토와 하이퍼파라미터 튜닝, 추가 검증 후 확정한다.

9. 실제 입력과 점수 산출

01 STT·메모·직접 입력	02 미팅 분석 Agent	03 특성 구성 현재 10 / 추후 22	04 ML 모델	05 딜 승산 점수
--------------------	-------------------	------------------------------	-------------	---------------

ML 모델의 Won 예측값에 100 을 곱해 화면용 점수로 변환한다.

표시 예시

딜 승산 점수 78 점 · 실험 모델 · 미팅 내용 기반

점수는 승인 없이 표시하지만 다른 Agent 를 실행하거나 영업 딜 단계와 실제 계약을 변경하지 않는다.

실행 결과 저장

필드	저장 내용
agent_code	meeting_analysis
source_refs	원천 activity_id + 대상 sales_deal_id
output_snapshot.deal_assessment	계산 시점의 적용 features + score + ML model_version
화면 표시	같은 sales_deal_id 의 완료 실행 중 finished_at DESC, id DESC 첫 행
재분석	기존 실행을 덮어쓰지 않고 새 agent_run 행 추가

10. 한계와 향후 재학습

현재 한계

현재 점수는 기능 시연과 참고 용도로 사용한다. 외부 B2B 딜 데이터와 10 개 특성 기반 1 차 실험 결과이므로 최종 운영 성능을 의미하지 않는다.

중복 제거 후 데이터가 365 건으로 작다.

같은 입력 특성에서도 실제 영업 딜 결과가 다른 사례가 있다.

현재는 22 개 후보 중 10 개 특성만 사용해 1 차 테스트했으며, 모델 비교와 튜닝 범위도 제한적이다.

데이터는 SalesLuv 의 한국어 영업 미팅이 아닌 외부 B2B 딜 데이터다.

원본에는 각 범주의 세부 판정 기준이 부족해 미팅 분석 Agent 에 일관된 변환 기준이 필요하다.

22 개 특성 확장 계획

향후에는 22 개 전체 컬럼을 입력 스키마로 구성한다. 미팅 또는 CRM 에서 확인된 값은 실제 범주로 입력하고, 확인되지 않은 값은 Unknown 으로 처리한다. 22 개 적용 전후의 성능과 Unknown 비율을 비교한 뒤 최종 특성 조합과 모델을 확정한다.

실제 종료 딜 기반 재학습 기준

결과	판정 기준	결과 시각
Won	outcome_code=confirmed + contract_signed_on 존재	contract_signed_on
Lost	outcome_code=cancelled + closed_on 존재	closed_on
학습 제외	outcome_code=in_progress	결과 없음

재학습 시에는 결과가 발생한 뒤의 정보가 입력에 섞이지 않도록 점수 계산 시점의 입력 특성과 이후 결과를 쌍으로 사용한다. Won 은 contract_signed_on, Lost 는 closed_on 보다 앞서 생성된 점수만 학습 표본으로 사용하며, closed_on 은 계약 체결일이나 매출 확정일로 사용하지 않는다.

11. 데이터 사용 주의사항

Hugging Face 데이터 카드에는 CC BY 4.0 으로 표시되어 있지만, Salvirt 공식 페이지에는 데이터셋의 별도 라이선스가 명확하게 적혀 있지 않다.

문서와 발표에 Salvirt 출처를 표시한다.

부트캠프 학습·시연 목적으로 사용한다.

원본 CSV 는 공개 저장소에 올리지 않는다.

상업적 사용이나 원본 재배포 전에는 Salvirt 에 사용 조건을 확인한다.

DATA USAGE

공개 데이터의 출처와 사용 조건을 명확히 표시하고, 원본 데이터의 공개 저장소 재배포는 하지 않는다.

참고 자료

자료	주소
Salvirt B2B Sales Dataset 공식 페이지	https://www.salvirt.com/research/b2bdataset/
Hugging Face 미러 데이터 카드	https://huggingface.co/datasets/markobo/B2B_Sales_data

SalesLuv

CONNECT THE HISTORY. APPROVE THE NEXT MOVE.

Machine Learning Model Documentation