

학습한 ML/DL 모델 산출물

deal-stacking-lr-v1 · 2026-08-26

항목	내용
제품	SalesLuv
모델 역할	B2B 딜의 Won 확률 및 승패 예측
모델 버전	deal-stacking-lr-v1
최종 모델	Stacking_LR
모델 유형	5개 기본 분류기 + LogisticRegression 메타모델
입력	13개 범주형 컬럼
분류 임계값	0.50
작성 기준일	2026-08-26
산출물 상태	전체 재학습·저장·해시·CPU 재로드 검증 완료, 백엔드 연결 전

1. 모델 카드


1.1 목적과 출력

구조화 Agent가 미팅 보고서에서 추출한 13개 범주형 값을 받아 계약 성사 클래스 Won의 확률을 계산한다.

출력	형식	설명
won_probability	0~1 실수	Stacking 메타모델의 P(Won)
predicted_class	Won / Lost	won_probability $\geq$ 0.50이면 Won
model_version	문자열	deal-stacking-lr-v1

모델 확률은 영업 판단을 지원하는 참고 정보다. 계약 승인, 딜 상태 변경, 담당자 평가는 서비스 운영 규칙과 사람이 결정한다.

1.2 구조



Stacking 메타모델은 기본 모델의 OOF 확률로 학습한다. 최종 추론에는 다섯 기본 모델이 모두 필요하다.

다섯 기본 모델은 선형 확률 모델(LogisticRegression), 빈도 기반 확률 모델(MultinomialNB), 비선형 배경 트리(ExtraTrees), 범주형 부스팅(CatBoost), 표형 파운데이션 모델(TabICL)을 각각 대표한다. 서로 다른 학습 방식의 확률을 비교하고 결합하기 위해 이 구성을 선택했다.

2. 입력 계약

2.1 필드 의미와 허용 범주

필드	의미	허용 범주
Authority	고객 의사결정권자의 권한 수준	High, Low, Mid, Unknown
Competitors	경쟁사 존재·검토 여부	No, Unknown, Yes
Purch_dept	고객사 구매부서 참여 여부	No, Unknown, Yes
Budgt_alloc	고객 예산 확보·배정 여부	No, Unknown, Yes
Forml_tend	공식 입찰 절차 여부	No, Unknown, Yes
RFP	제안요청서 진행 여부	No, Unknown, Yes
Posit_statm	고객의 명시적 구매 표현	Neutral, No, Unknown, Yes
Source	영업기회 유입 경로	Direct mail, Event, Joint past, Media, Online form, Other, Referral, Unknown
Client	고객과의 거래 관계	Current, New, Past, Unknown
Scope	계약·수행 범위의 명확성	Clear, Few questions, Low, Unknown
Cross_sale	기존 고객 대상 교차판매 여부	No, Unknown, Yes
Deal_type	거래 유형	Consulting, Maintenance, Project, Solution, Unknown
Needs_def	고객 요구사항의 정의 수준	Info gathering, No, Poor, Unknown, Yes

2.2 검증 규칙

검증 항목	규칙
필드	요청은 13개 필드를 모두 포함한다.
결측	측정되지 않은 값과 빈값은 구조화 단계에서 문자열 Unknown으로 변환한다.
범주	허용 목록에 없는 범주는 입력 오류로 처리한다.
스키마	컬럼 이름과 순서를 저장된 모델 스키마와 대조한다.
정답	학습 정답은 Lost=0, Won=1로 매핑한다.

3. 전처리 계약과 최적 파라미터

모델 입력은 다음 순서로 정규화한다.

1. 문자열 앞뒤 공백을 제거한다. 의미가 있는 값은 임의로 바꾸지 않는다.

2. 빈값과 측정되지 않은 값은 No가 아닌 문자열 Unknown으로 변환한다.
3. 13개 필드의 존재 여부, 순서, 허용 범주를 저장된 스키마와 대조한다.
4. LogisticRegression, MultinomialNB, ExtraTrees는 고정 범주 One-Hot Encoder로 39개 컬럼을 만든다.
5. CatBoost와 TablCL은 범주 정보를 보존하기 위해 원본 13개 범주형 컬럼을 직접 사용한다.

학습 단계의 30% 마스킹은 값 누락에 대한 강건성을 확보하기 위한 데이터 증강이다. 실제 추론에서는 구조화 Agent가 확인하지 못한 필드만 Unknown으로 전달하며, 임의로 네 개를 다시 마스킹하지 않는다.

모델	선택 파라미터
LogisticRegression	C=0.03, class_weight="balanced"
MultinomialNB	alpha=75.0, fit_prior=False
ExtraTrees	n_estimators=300, max_depth=8, max_features="sqrt", min_samples_leaf=6
CatBoost	iterations=200, depth=4, learning_rate=0.01, l2_leaf_reg=7.0, random_strength=0.5
TablCL	n_estimators=8, norm_methods="quantile", feat_shuffle_method="latin", average_logits=True, softmax_temperature=1.1
Stacking meta	LogisticRegression(C=0.1, max_iter=3000, solver="lbfgs")

4. 학습 데이터와 성능 근거

항목	값
데이터 출처	Salvirt B2B Sales Dataset, 실제 익명화 B2B 영업기획
원본 파일 SHA-256	8dee635b95bdc00896b654efe62fc20177090081c81ef5224e8641ba31c3061
원본	448건, Lost 221 / Won 227
평가 분할	Train 313건 / Test 135건, 입력 그룹 분리
마스킹	행마다 13개 중 4개 Unknown, 서로 다른 10세트
최종 재학습	전체 448건 × 10세트 = 4,480행
최종 재학습 그룹	198개

지표	반복 Group CV	Test 10세트 평균
Brier ↓	0.194406 ± 0.001928	0.179131 ± 0.005902
ROC-AUC ↑	0.766326	0.817164
Accuracy ↑	0.720873	0.734074
Precision ↑	0.695164	0.720534
Recall ↑	0.802935	0.772059
F1 ↑	0.745072	0.745083
FP / FN	56.03 / 31.33	20.4 / 15.5

보고 성능은 4단계의 분리 평가 결과다. 저장된 배포 모델은 모델 선택 이후 전체 448건으로 다시 학습했다.

모델과 하이퍼파라미터는 Won 확률의 정확성을 평가하는 Brier Score를 기준으로 선택했다. ROC-AUC와 Accuracy-F1은 보조 지표로 확인했고, FP/FN은 분류 임계값 적용 후의 업무 위험을 확인하는 지표로 사용했다. 특히 FP가 발생하면 실제로는 추가 관리가 필요한 Lost 위험 거래가 쉽게 성사될 거래처럼 표시된다. 이로 인해 위험 신호와 개입 시점을 놓치고 파이프라인과 예상 매출을 실제보다 낙관적으로 평가할 수 있다. 현재 모델의 임계값은 0.50으로 확정했으며, FP/FN은 운영 모니터링 지표로 기록한다.

5. 배포 아티팩트

저장 위치:

backend/pipeline/artifacts/

파일	역할	크기	SHA-256
deal-stacking-lr-v1-models.joblib	LR·NB·ExtraTrees·CatBoost·Stacking 메타모델·입력 스키마	1,316,974 bytes	97d363b2f3f628ea4b5f0a9fa3946bd420d94677172e6f09e5e7a4cecfdb8db5
deal-stacking-lr-v1-tabicl.pkl	TabICL 가중치와 전체 학습 문맥	111,436,285 bytes	6de049ae1fa14cd347fb2cc743014b7b7ede45a646b8aaeaa605ced461e0f90c
deal-stacking-lr-v1.json	모델·스키마·평가·환경·해시·기준 확률 메타데이터	11,510 bytes	46238930b660e8e7bd497fab0a25feabdea6801d52cc18f8793ad49593cbb8a

joblib과 pickle 계열 파일은 로드 과정에서 코드를 실행할 수 있다. 신뢰할 수 있는 릴리스의 파일만 사용하고 로드 전에 SHA-256을 확인한다.

6. 저장·재로드 검증

검증 항목	결과
현재 프로세스 재로드	통과
현재 프로세스 최대 확률 차이	0
새 CPU 프로세스 재로드	통과
새 CPU 프로세스 최대 확률 차이	1.0451534443456367e-06
허용오차	rtol=1e-5, atol=1e-6
모델 파일 SHA-256	메타데이터와 일치

재로드 검사는 메타데이터에 저장된 범주형 기준 입력 16건으로 수행했다.

7. 재현 환경과 파일

패키지	버전
Python	3.13.13
pandas	3.0.5
scikit-learn	1.9.0
CatBoost	1.2.10
TabICL	2.1.1
PyTorch	2.13.0
joblib	1.5.3

```

backend/notebooks/deal_data_preprocessing.ipynb
backend/notebooks/deal_model_phase2.ipynb
backend/notebooks/deal_model_phase3.ipynb
backend/notebooks/deal_model_phase4.ipynb
backend/notebooks/deal_model_phase5_threshold.ipynb
backend/notebooks/deal_model_finalization.ipynb
backend/notebooks/pyproject.toml
backend/notebooks/uv.lock

```

TabICL 최종 학습에는 MPS를 사용했고 새 프로세스 검증에는 CPU를 사용했다.

8. 백엔드 연결 체크리스트

- ☐ 모델 파일 3개를 동일 버전으로 배포
- ☐ 프로세스 시작 시 SHA-256 검증 후 한 번 로드
- ☐ 13개 필드·허용 범주·컬럼 순서 검증
- ☐ 빈값을 `Unknown`으로 정규화
- ☐ 다섯 기본 확률을 메타모델 입력 순서대로 결합
- ☐ 응답에 `won_probability`, `predicted_class`, `model_version` 포함
- ☐ 추론 지연시간과 오류 로그 기록
- ☐ 실제 승패 확정 후 결측률·확률 품질·FP/FN 모니터링